

เรื่อง

การวิเคราะห์ข้อมูลลูกค้าเพื่อพัฒนากลยุทธ์เพิ่มยอดขายและรักษาฐานลูกค้า

จัดทำโดย

นางสาวพัชณกัญญ์ คชาวุธากร

เสนอ

ดร. ปาณิตา ธูสรานนท์

โครงงานนี้เป็นส่วนหนึ่งของรายวิชา 06026211 การเรียนรู้ของเครื่องเชิงประยุกต์

คณะเทคโนโลยีสารสนเทศ สาขาวิทยาการข้อมูลและการวิเคราะห์เชิงธุรกิจ

สถาบันเทคโนโลยีพระจอมเกล้าเจ้าคุณทหารลาดกระบัง

ภาคเรียนที่ 1 ปีการศึกษา 2569

คำนำ

รายงานฉบับนี้จัดทำขึ้นเป็นส่วนหนึ่งของการศึกษาในรายวิชา 06026211 การเรียนรู้ของเครื่องเชิงประยุกต์ โดยมีวัตถุประสงค์เพื่อศึกษาและประยุกต์ใช้กระบวนการวิเคราะห์ข้อมูลในการทำความเข้าใจพฤติกรรมของลูกค้า เพื่อสนับสนุนการวางแผนและพัฒนากลยุทธ์ทางธุรกิจสำหรับการเพิ่มยอดขายและการรักษาฐานลูกค้า

ในการดำเนินโครงงาน ผู้จัดทำได้นำกระบวนการ CRISP-DM (Cross-Industry Standard Process for Data Mining) มาใช้เป็นแนวทางในการวิเคราะห์ข้อมูล ตั้งแต่การทำความเข้าใจปัญหาทางธุรกิจ การทำความเข้าใจและเตรียมข้อมูล การสร้างแบบจำลอง การประเมินผล ตลอดจนการนำผลลัพธ์ที่ได้มาวิเคราะห์และตีความ โดยมุ่งเน้นการศึกษาพฤติกรรมการซื้อของลูกค้า การแบ่งกลุ่มลูกค้าตามลักษณะและพฤติกรรม รวมถึงการวิเคราะห์แนวโน้มการรักษาฐานลูกค้า เพื่อให้ได้ข้อค้นพบที่สามารถนำไปใช้ประกอบการกำหนดกลยุทธ์ทางธุรกิจได้อย่างเหมาะสม

ผู้จัดทำหวังเป็นอย่างยิ่งว่ารายงานฉบับนี้จะเป็นประโยชน์ต่อการศึกษาและทำความเข้าใจการประยุกต์ใช้การวิเคราะห์ข้อมูลกับปัญหาทางธุรกิจ รวมถึงสามารถใช้เป็นแนวทางในการต่อยอดการวิเคราะห์และพัฒนากลยุทธ์ด้านการขายและการบริหารความสัมพันธ์กับลูกค้าในอนาคต

คณะผู้จัดทำ

สารบัญ

เรื่อง **หน้า**

คำนำ .....ก

สารบัญ .....ข

บทที่

1. บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา.....1

1.2 วัตถุประสงค์ของโครงงาน.....1

1.3 ขอบเขตของโครงงาน.....2

1.4 ประโยชน์ที่คาดว่าจะได้รับ.....2

1.5 โครงสร้างของรายงาน.....2

2. ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

2.1 การวิเคราะห์ข้อมูลลูกค้า (Customer Analytics).....4

2.2 การวิเคราะห์ตะกร้าสินค้า (Market Basket Analysis).....4

2.2.1 Association Rule Mining.....5

2.2.2 Apriori Algorithm.....5

2.2.3 FP-Growth Algorithm.....5

2.2.4 การประเมิน Association Rules 6

2.3 การแบ่งกลุ่มลูกค้า (Customer Segmentation) 6

2.3.1 RFM Analysis.....6

2.3.2 K-Means Clustering.....7

2.3.3 การประเมินผลการแบ่งกลุ่ม....7
2.4 การวิเคราะห์การรักษาลูกค้า (Customer Retention Analysis)....7
2.4.1 Customer Churn....8
2.4.2 Binary Classification....8
2.4.3 Logistic Regression....8
2.4.4 การประเมินประสิทธิภาพ Classification....9
2.5 การเตรียมข้อมูลสำหรับการวิเคราะห์ (Data Preprocessing)....9
2.6 กระบวนการ CRISP-DM....10
2.7 เครื่องมือและเทคโนโลยีที่ใช้....10
3. ขั้นตอนการดำเนินงาน
3.1 ภาพรวมกระบวนการทำงาน....12
3.2 Business Understanding....13
3.2.1 ปัญหาทางธุรกิจ....13
3.2.2 คำถามทางธุรกิจ....13
3.2.3 เป้าหมายของการวิเคราะห์....13
3.2.4 เกณฑ์ความสำเร็จของโครงงาน....14
3.3 Data Understanding....14
3.3.1 รายละเอียดชุดข้อมูล....14
3.3.2 การสำรวจและตรวจสอบคุณภาพข้อมูล....15
3.4 Data Preparation....15
3.4.1 การทำความสะอาดข้อมูล....15
3.4.2 การเตรียมข้อมูลสำหรับ Basket Analysis....16

3.4.3 การเตรียมข้อมูลสำหรับ Customer Segmentation 16
3.4.4 การเตรียมข้อมูลสำหรับ Customer Retention 16
3.5 Modeling 16
3.5.1 การวิเคราะห์ Increase Basket Size 17
3.5.2 การแบ่งกลุ่มลูกค้า 17
3.5.3 การวิเคราะห์ Customer Retention 17
3.6 Evaluation 17
3.7 Deployment 18
4. ผลการดำเนินงาน
4.1 ผลการเตรียมและสำรวจข้อมูล 19
4.2 ผลการวิเคราะห์ Increase Basket Size 19
4.3 ผลการแบ่งกลุ่มลูกค้า 21
4.3.1 ผลการเลือกจำนวน Cluster 21
4.3.2 ลักษณะของลูกค้าแต่ละกลุ่ม 22
4.4 ผลการวิเคราะห์ Customer Retention 22
4.4.1 ผลการเปรียบเทียบแบบจำลอง 22
4.4.2 พฤติกรรมที่สัมพันธ์กับ Customer Churn 23
4.4.3 การตีความเชิงธุรกิจ 24
5. สรุปผลการดำเนินงาน
5.1 สรุปผลการดำเนินโครงงาน 26
5.2 สรุปผลตามคำถามทางธุรกิจ 26
5.2.1 Increase Basket Size 26

5.2.2 Customer Segmentation 26

5.2.3 Customer Retention 27

5.3 ข้อเสนอแนะเชิงธุรกิจ 27

5.4 ข้อจำกัดของโครงงาน 27

5.5 แนวทางการพัฒนาในอนาคต 28

บรรณานุกรม 29

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบัน ข้อมูลลูกค้าและข้อมูลธุรกรรมมีบทบาทสำคัญต่อการดำเนินธุรกิจ เนื่องจากสามารถนำมาใช้เพื่อทำความเข้าใจพฤติกรรม ความต้องการ และรูปแบบการซื้อของลูกค้าได้ การนำข้อมูลเหล่านี้มาวิเคราะห์อย่างเหมาะสมจึงสามารถช่วยสนับสนุนการตัดสินใจและการวางแผนกลยุทธ์ทางธุรกิจได้อย่างมีประสิทธิภาพมากขึ้น

อย่างไรก็ตาม ลูกค้าแต่ละรายมีพฤติกรรมการซื้อที่แตกต่างกัน ทั้งในด้านประเภทสินค้า ความถี่ในการซื้อและมูลค่าการใช้จ่าย อีกทั้งยังมีสินค้าบางประเภทที่มีแนวโน้มถูกซื้อร่วมกัน รวมถึงลูกค้าบางส่วนที่อาจลดความถี่หรือหยุดซื้อสินค้า การวิเคราะห์ข้อมูลดังกล่าวจึงช่วยให้สามารถค้นหารูปแบบการซื้อ แบ่งกลุ่มลูกค้าตามพฤติกรรม และระบุลูกค้าที่มีแนวโน้มจะหยุดซื้อได้

ดังนั้น โครงงานนี้จึงนำการวิเคราะห์ข้อมูลลูกค้า (Customer Analytics) มาประยุกต์ใช้ โดยมุ่งเน้นการวิเคราะห์ใน 3 ด้าน ได้แก่ การเพิ่มมูลค่าการซื้อต่อธุรกรรม (Increase Basket Size) การแบ่งกลุ่มลูกค้า (Customer Segmentation) และการรักษาฐานลูกค้า (Customer Retention) เพื่อให้ได้ข้อมูลที่สามารถนำไปใช้เป็นแนวทางในการพัฒนากลยุทธ์เพิ่มยอดขายและรักษาฐานลูกค้า

1.2 วัตถุประสงค์ของโครงงาน

โครงงานนี้มีวัตถุประสงค์เพื่อประยุกต์ใช้เทคนิคการวิเคราะห์ข้อมูลในการศึกษาพฤติกรรมของลูกค้า และนำผลที่ได้มาสนับสนุนการพัฒนากลยุทธ์ทางธุรกิจ โดยมีวัตถุประสงค์ดังนี้

1. เพื่อวิเคราะห์ความสัมพันธ์ของสินค้าที่มีแนวโน้มถูกซื้อร่วมกัน และใช้เป็นแนวทางในการเพิ่มมูลค่าการซื้อต่อธุรกรรม
2. เพื่อแบ่งกลุ่มลูกค้าตามพฤติกรรมการซื้อ และศึกษาลักษณะที่สำคัญของลูกค้าแต่ละกลุ่ม
3. เพื่อวิเคราะห์ลูกค้าที่มีแนวโน้มจะหยุดซื้อ และศึกษาพฤติกรรมที่เป็นสัญญาณของการสูญเสียลูกค้า
4. เพื่อนำผลการวิเคราะห์มาใช้เป็นแนวทางในการพัฒนากลยุทธ์เพิ่มยอดขายและรักษาฐานลูกค้า

1.3 ขอบเขตของโครงงาน

โครงงานนี้มุ่งเน้นการวิเคราะห์ข้อมูลลูกค้าและข้อมูลธุรกรรม เพื่อศึกษาพฤติกรรมการซื้อและนำผลการวิเคราะห์ไปใช้สนับสนุนการตัดสินใจทางธุรกิจ โดยแบ่งขอบเขตออกเป็น 3 ด้าน ดังนี้

1. ขอบเขตด้านข้อมูล ศึกษาข้อมูลที่เกี่ยวข้องกับลูกค้า สินค้า และธุรกรรมการซื้อ รวมถึงข้อมูลอื่นที่เกี่ยวข้องกับพฤติกรรมและสถานะของลูกค้า โดยมีการตรวจสอบและเตรียมข้อมูลก่อนนำไปใช้ในการวิเคราะห์
2. ขอบเขตด้านการวิเคราะห์ แบ่งการวิเคราะห์ออกเป็น 3 ส่วน ได้แก่ การวิเคราะห์ความสัมพันธ์ของสินค้าที่ซื้อร่วมกันเพื่อเพิ่มมูลค่าการซื้อต่อธุรกรรม การแบ่งกลุ่มลูกค้าตามพฤติกรรมการซื้อ และการวิเคราะห์แนวโน้มการหยุดซื้อของลูกค้า
3. ขอบเขตด้านเทคนิคและเครื่องมือ ดำเนินการวิเคราะห์ด้วยภาษา Python โดยประยุกต์ใช้เทคนิคด้านการวิเคราะห์ข้อมูลและ Machine Learning ที่เหมาะสมกับแต่ละปัญหา และดำเนินงานตามกระบวนการ CRISP-DM ตั้งแต่การทำความเข้าใจปัญหา การเตรียมข้อมูล การสร้างแบบจำลอง การประเมินผล และการนำผลลัพธ์ไปใช้

1.4 ประโยชน์ที่คาดว่าจะได้รับ

จากการดำเนินโครงงานคาดว่าจะได้รับประโยชน์ดังต่อไปนี้

1. สามารถค้นหารูปแบบความสัมพันธ์ของสินค้าที่มักถูกซื้อร่วมกัน เพื่อนำไปใช้เป็นแนวทางในการเพิ่มมูลค่าการซื้อต่อธุรกรรม
2. สามารถแบ่งกลุ่มและทำความเข้าใจลักษณะของลูกค้าตามพฤติกรรมการซื้อ เพื่อสนับสนุนการวางแผนกลยุทธ์สำหรับลูกค้าแต่ละกลุ่ม
3. สามารถระบุลูกค้าที่มีแนวโน้มจะหยุดซื้อ รวมถึงพฤติกรรมที่อาจเป็นสัญญาณของการสูญเสียลูกค้า
4. สามารถนำผลการวิเคราะห์มาใช้เป็นข้อมูลสนับสนุนการวางแผนกลยุทธ์ในการเพิ่มยอดขายและรักษาฐานลูกค้า

1.5 โครงสร้างของรายงาน

รายงานฉบับนี้แบ่งเนื้อหาออกเป็น 5 บท โดยมีรายละเอียดโดยสรุปดังต่อไปนี้

บทที่ 1 บทนำ กล่าวถึงความเป็นมาและความสำคัญของปัญหา วัตถุประสงค์ ขอบเขตของโครงงาน ประโยชน์ที่คาดว่าจะได้รับ และโครงสร้างของรายงาน

บทที่ 2 ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง กล่าวถึงแนวคิด ทฤษฎี เทคนิค และเครื่องมือที่เกี่ยวข้องกับการดำเนินโครงงาน เช่น Customer Analytics, Association Rule Mining, RFM, K-Means Clustering, Customer Churn, Classification และกระบวนการ CRISP-DM

บทที่ 3 ขั้นตอนการดำเนินงาน กล่าวถึงกระบวนการดำเนินโครงงานตามแนวทาง CRISP-DM ตั้งแต่ Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation และ Deployment รวมถึงรายละเอียดของการเตรียมข้อมูลและวิธีการวิเคราะห์สำหรับปัญหาทางธุรกิจทั้งสามด้าน

บทที่ 4 ผลการดำเนินงาน นำเสนอผลจากการวิเคราะห์ความสัมพันธ์ของสินค้า การแบ่งกลุ่มลูกค้า และการวิเคราะห์ Customer Retention รวมถึงการประเมินผล การตีความผลลัพธ์ และแนวทางในการนำผลการวิเคราะห์ไปประยุกต์ใช้ในเชิงธุรกิจ

บทที่ 5 สรุปผลการดำเนินงาน สรุปผลการวิเคราะห์ตามวัตถุประสงค์ของโครงงาน นำเสนอข้อเสนอแนะเชิงธุรกิจ ข้อจำกัดของการวิเคราะห์ และแนวทางสำหรับการพัฒนาหรือต่อยอดในอนาคต

บทที่ 2

ทฤษฎีและเทคโนโลยีที่เกี่ยวข้อง

โครงงานการวิเคราะห์ข้อมูลลูกค้าเพื่อพัฒนากลยุทธ์เพิ่มยอดขายและรักษาฐานลูกค้า มีการประยุกต์ใช้แนวคิดด้านการวิเคราะห์ข้อมูล การเรียนรู้ของเครื่อง และเทคนิคทางสถิติ เพื่อศึกษาพฤติกรรมการซื้อของลูกค้า ค้นหาความสัมพันธ์ระหว่างสินค้า แบ่งกลุ่มลูกค้า และวิเคราะห์แนวโน้มการหยุดซื้อสินค้า โดยทฤษฎีและเทคโนโลยีที่เกี่ยวข้องกับการดำเนินโครงงานมีรายละเอียดดังต่อไปนี้

2.1 การวิเคราะห์ข้อมูลลูกค้า (Customer Analytics)

การวิเคราะห์ข้อมูลลูกค้า (Customer Analytics) เป็นกระบวนการนำข้อมูลที่เกี่ยวข้องกับลูกค้ามาวิเคราะห์ เพื่อทำความเข้าใจลักษณะ พฤติกรรม และรูปแบบการซื้อสินค้า โดยข้อมูลที่นำมาวิเคราะห์อาจประกอบด้วยข้อมูลพื้นฐานของลูกค้า ข้อมูลธุรกรรม รายละเอียดสินค้า ช่องทางการซื้อ และข้อมูลการให้บริการลูกค้า

ผลจากการวิเคราะห์สามารถนำมาใช้สนับสนุนการตัดสินใจทางธุรกิจ เช่น การเลือกสินค้าที่เหมาะสมสำหรับการส่งเสริมการขาย การแบ่งกลุ่มลูกค้าเพื่อกำหนดกลยุทธ์ทางการตลาด และการค้นหาลูกค้าที่มีความเสี่ยงต่อการหยุดซื้อสินค้า

สำหรับโครงงานนี้ การวิเคราะห์ข้อมูลลูกค้าแบ่งออกเป็น 3 ส่วนหลัก ได้แก่ การวิเคราะห์สินค้าที่มีแนวโน้มถูกซื้อร่วมกันเพื่อเพิ่มมูลค่าการซื้อต่อธุรกรรม การแบ่งกลุ่มลูกค้าตามพฤติกรรมการซื้อ และการวิเคราะห์แนวโน้มการหยุดซื้อของลูกค้า

2.2 การวิเคราะห์ตะกร้าสินค้า (Market Basket Analysis)

การวิเคราะห์ตะกร้าสินค้า (Market Basket Analysis) เป็นเทคนิคที่ใช้ค้นหารูปแบบความสัมพันธ์ของสินค้าที่ปรากฏร่วมกันในธุรกรรม โดยพิจารณาว่าลูกค้ามักซื้อสินค้าชนิดใดร่วมกัน ข้อมูลที่ได้สามารถนำไปใช้สนับสนุนการทำ Cross-selling การจัด Bundle Promotion การแนะนำสินค้า และการวางแผนส่งเสริมการขาย

ในโครงงานนี้ใช้ Association Rule Mining ในการค้นหาความสัมพันธ์ของสินค้า และเปรียบเทียบอัลกอริทึม Apriori และ FP-Growth ภายใต้เกณฑ์เดียวกัน เพื่อค้นหารูปแบบสินค้าที่เหมาะสมสำหรับการเพิ่ม Basket Size

2.2.1 Association Rule Mining

Association Rule Mining เป็นเทคนิคสำหรับค้นหาความสัมพันธ์ระหว่างรายการที่เกิดขึ้นร่วมกันภายในชุดข้อมูล โดยเริ่มจากการค้นหา Frequent Itemsets หรือกลุ่มสินค้าที่ปรากฏร่วมกันบ่อย แล้วนำมาสร้างเป็นกฎความสัมพันธ์ในรูปแบบ $A \rightarrow B$ ซึ่งหมายถึง เมื่อเกิดการซื้อสินค้า A มีแนวโน้มที่จะพบการซื้อสินค้า B ร่วมด้วย

กฎที่ค้นพบสามารถนำมาพิจารณาเพื่อหาคู่หรือกลุ่มสินค้าที่เหมาะสมสำหรับการทำโปรโมชันหรือการแนะนำสินค้าให้แก่ลูกค้า

2.2.2 Apriori Algorithm

Apriori เป็นอัลกอริทึมสำหรับค้นหา Frequent Itemsets โดยอาศัยหลักการว่าหากชุดสินค้าหนึ่งเป็น Frequent Itemset ชุดย่อยของสินค้านั้นควรเป็น Frequent Itemset เช่นเดียวกัน อัลกอริทึมจะเริ่มค้นหาจากสินค้าทีละรายการและเพิ่มจำนวนสินค้าภายในชุดขึ้นตามลำดับ พร้อมตัดชุดสินค้าที่ไม่ผ่านค่า Minimum Support ที่กำหนดออก

ข้อดีของ Apriori คือมีหลักการทำงานที่ไม่ซับซ้อนและสามารถตีความได้ง่าย อย่างไรก็ตาม เมื่อมีข้อมูลจำนวนมากหรือมีรายการสินค้าจำนวนมาก การสร้าง Candidate Itemsets อาจทำให้ต้องใช้เวลาในการประมวลผลเพิ่มขึ้น

2.2.3 FP-Growth Algorithm

FP-Growth (Frequent Pattern Growth) เป็นอีกอัลกอริทึมหนึ่งสำหรับค้นหา Frequent Itemsets โดยลดความจำเป็นในการสร้าง Candidate Itemsets แบบ Apriori ด้วยการจัดเก็บรูปแบบการเกิดร่วมกันของสินค้าในโครงสร้างที่เรียกว่า FP-Tree และใช้โครงสร้างดังกล่าวในการค้นหา Frequent Patterns

FP-Growth จึงเป็นอีกวิธีที่สามารถนำมาใช้สำหรับ Market Basket Analysis ได้ ในโครงงานนี้มีการทดลองทั้ง Apriori และ FP-Growth ด้วยเงื่อนไขเดียวกัน และเปรียบเทียบผลลัพธ์และระยะเวลาในการประมวลผลของทั้งสองวิธี

2.2.4 การประเมิน Association Rules

การประเมินความสัมพันธ์ของสินค้าในโครงงานใช้ตัวชี้วัดหลัก ได้แก่ Support, Confidence และ Lift โดย Support แสดงความถี่ที่ชุดสินค้าปรากฏในธุรกรรม Confidence แสดงความน่าจะเป็นที่จะพบสินค้า B เมื่อพบสินค้า A และ Lift ใช้พิจารณาความสัมพันธ์ของสินค้าสองกลุ่มเมื่อเทียบกับการเกิดขึ้นอย่างเป็นอิสระ

โดยทั่วไป ค่า Lift ที่มากกว่า 1 แสดงว่าสินค้ามีแนวโน้มเกิดร่วมกันมากกว่าที่คาดจากการเกิดอย่างอิสระ นอกจากนี้ โครงงานยังพิจารณาจำนวน Frequent Itemsets และ Execution Time เพื่อเปรียบเทียบประสิทธิภาพของ Apriori และ FP-Growth

2.3 การแบ่งกลุ่มลูกค้า (Customer Segmentation)

การแบ่งกลุ่มลูกค้า (Customer Segmentation) เป็นกระบวนการแบ่งลูกค้าออกเป็นกลุ่มตามลักษณะหรือพฤติกรรมที่คล้ายคลึงกัน เพื่อช่วยให้ธุรกิจเข้าใจความแตกต่างของลูกค้าแต่ละกลุ่ม และสามารถกำหนดกลยุทธ์ทางการตลาด การส่งเสริมการขาย หรือการดูแลลูกค้าให้เหมาะสมมากขึ้น

โครงงานนี้แบ่งกลุ่มลูกค้าจากพฤติกรรมการซื้อโดยใช้แนวคิด RFM Analysis ร่วมกับ K-Means Clustering เพื่อค้นหากลุ่มลูกค้าที่มีรูปแบบการซื้อใกล้เคียงกัน

2.3.1 RFM Analysis

RFM Analysis เป็นแนวคิดสำหรับวิเคราะห์พฤติกรรมของลูกค้าจากข้อมูลการซื้อ โดยประกอบด้วยตัวแปร 3 ด้าน ได้แก่

- Recency (R) ระยะเวลาตั้งแต่การซื้อครั้งล่าสุดของลูกค้า
- Frequency (F) จำนวนครั้งที่ลูกค้าทำรายการซื้อสินค้า
- Monetary (M) มูลค่าการใช้จ่ายรวมของลูกค้า

ตัวแปรทั้งสามสามารถสะท้อนพฤติกรรมและคุณค่าของลูกค้าในมุมที่แตกต่างกัน เช่น ลูกค้าที่ซื้อสินค้าเมื่อไม่นานมานี้ ซื้อบ่อย และมียอดใช้จ่ายสูง อาจเป็นกลุ่มลูกค้าที่มีคุณค่าต่อธุรกิจ ในขณะที่ลูกค้าที่ไม่ได้ซื้อสินค้าเป็นระยะเวลานานอาจเป็นกลุ่มที่ควรได้รับการกระตุ้นให้กลับมาซื้อสินค้าอีกครั้ง

2.3.2 K-Means Clustering

K-Means เป็นอัลกอริทึมการเรียนรู้แบบไม่มีผู้สอน (Unsupervised Learning) ที่ใช้แบ่งข้อมูลออกเป็นจำนวน K กลุ่ม โดยพยายามจัดข้อมูลที่มีลักษณะใกล้เคียงกันให้อยู่ในกลุ่มเดียวกัน และให้ข้อมูลที่มีลักษณะแตกต่างกันอยู่คนละกลุ่ม

ในการดำเนินโครงงาน ใช้ค่า Recency, Frequency และ Monetary เป็นตัวแปรสำหรับ K-Means โดยมีการปรับข้อมูลด้วย Log Transformation และ Standardization ก่อนสร้างโมเดล เพื่อลดผลกระทบจากการกระจายของข้อมูลที่เบ้และความแตกต่างของช่วงค่าระหว่างตัวแปร

2.3.3 การประเมินผลการแบ่งกลุ่ม

จำนวนกลุ่มที่เหมาะสมสำหรับ K-Means สามารถพิจารณาได้จากหลายวิธี ในโครงงานนี้ใช้ Elbow Method และ Silhouette Score ร่วมกับการพิจารณาความสามารถในการตีความกลุ่มในเชิงธุรกิจ

Elbow Method พิจารณาการเปลี่ยนแปลงของ Within-Cluster Sum of Squares (WCSS) เมื่อเพิ่มจำนวน Cluster ส่วน Silhouette Score ใช้วัดว่าข้อมูลภายในกลุ่มเดียวกันมีความใกล้เคียงกันและแตกต่างจากกลุ่มอื่นมากเพียงใด หลังจากเลือกจำนวนกลุ่มแล้วจึงวิเคราะห์ Cluster Profile จากค่า RFM เพื่ออธิบายลักษณะและกำหนดความหมายของลูกค้าแต่ละกลุ่ม

2.4 การวิเคราะห์การรักษาลูกค้า (Customer Retention Analysis)

Customer Retention เป็นแนวคิดที่มุ่งเน้นการรักษาลูกค้าเดิมให้ยังคงซื้อสินค้าหรือใช้บริการของธุรกิจอย่างต่อเนื่อง โดยหนึ่งในปัญหาสำคัญคือ Customer Churn หรือการที่ลูกค้าหยุดซื้อสินค้าหรือหยุดใช้บริการ

การวิเคราะห์ Customer Retention สามารถนำข้อมูลพฤติกรรมในอดีตมาใช้ค้นหาลูกค้าที่มีแนวโน้มจะ Churn เพื่อให้ธุรกิจสามารถดำเนินมาตรการรักษาลูกค้าได้ล่วงหน้า เช่น การส่งโปรโมชัน การแนะนำสินค้า หรือการทำ Win-back Campaign

2.4.1 Customer Churn

Customer Churn หมายถึงการที่ลูกค้าหยุดซื้อสินค้าหรือใช้บริการตามเงื่อนไขที่กำหนด สำหรับโครงงานนี้กำหนดให้ลูกค้าเป็น Churn เมื่อไม่มีการซื้อสินค้าเป็นระยะเวลามากกว่า 90 วัน ณ วันที่อ้างอิงที่กำหนด

ในการสร้างโมเดลจำเป็นต้องแยกข้อมูลที่ใช้สร้างตัวแปรสำหรับการทำนายออกจากข้อมูลที่ใช้กำหนดผลลัพธ์ เพื่อป้องกัน Data Leakage หรือการที่โมเดลได้รับข้อมูลซึ่งไม่ควรทราบในขณะที่ทำการทำนาย

2.4.2 Binary Classification

Binary Classification เป็นการจำแนกข้อมูลออกเป็นสองกลุ่ม ในโครงงานนี้กำหนด Target เป็นสถานะ Churn โดย 1 หมายถึงลูกค้าที่ Churn และ 0 หมายถึงลูกค้าที่ยังคง Active

ตัวแปรที่ใช้สำหรับการทำนายสร้างจากพฤติกรรมของลูกค้าในช่วงเวลาที่กำหนด เช่น Recency จำนวนธุรกรรมในช่วงเวลาต่าง ๆ ยอดใช้จ่าย มูลค่าต่อ Basket การใช้ส่วนลด ความหลากหลายของสินค้าและช่องทาง รวมถึงข้อมูลด้านการให้บริการลูกค้า

2.4.3 Logistic Regression

Logistic Regression เป็นอัลกอริทึมที่ใช้สำหรับปัญหา Classification โดยสามารถประมาณความน่าจะเป็นที่ข้อมูลจะอยู่ในกลุ่มใดกลุ่มหนึ่ง จึงสามารถนำมาใช้ประมาณความน่าจะเป็นที่ลูกค้าจะ Churn ได้

โครงงานนี้มีการทดลอง Logistic Regression ทั้งแบบพื้นฐานและแบบกำหนด class_weight = "balanced" เพื่อจัดการกับความไม่สมดุลของข้อมูลระหว่างลูกค้า Active และ Churn การใช้

Balanced Logistic Regression ช่วยเพิ่มความสำคัญของกลุ่มข้อมูลที่มีจำนวนน้อยกว่า และช่วยให้โมเดลสามารถตรวจพบลูกค้าที่ Churn ได้มากขึ้น

2.4.4 การประเมินประสิทธิภาพ Classification

การประเมิน Classification Model ไม่ควรพิจารณาจาก Accuracy เพียงอย่างเดียว โดยเฉพาะเมื่อจำนวนข้อมูลของแต่ละ Class ไม่สมดุล โครงงานนี้จึงใช้ตัวชี้วัดหลายค่า ได้แก่ Accuracy, Precision, Recall, F1-Score, ROC-AUC และ PR-AUC

Precision แสดงสัดส่วนของลูกค้าที่ Churn จริงจากลูกค้าที่โมเดลระบุว่าเสี่ยง ขณะที่ Recall แสดงความสามารถในการตรวจพบลูกค้าที่ Churn จริง ส่วน F1-Score ใช้พิจารณาสมดุลระหว่าง Precision และ Recall สำหรับ ROC-AUC และ PR-AUC ใช้ประเมินความสามารถของโมเดลในการจำแนกกลุ่มในภาพรวม

สำหรับปัญหา Customer Retention ให้ความสำคัญกับ Recall เนื่องจาก False Negative หมายถึงลูกค้าที่มีความเสี่ยง Churn แต่โมเดลไม่สามารถตรวจพบได้ ทำให้ธุรกิจอาจสูญเสียโอกาสในการดำเนินมาตรการรักษาลูกค้ารายนั้น

2.5 การเตรียมข้อมูลสำหรับการวิเคราะห์ (Data Preprocessing)

การเตรียมข้อมูล (Data Preprocessing) เป็นขั้นตอนสำคัญก่อนการวิเคราะห์และสร้างแบบจำลอง เนื่องจากข้อมูลจริงอาจมีปัญหา เช่น ข้อมูลซ้ำ ข้อมูลสูญหาย ค่าที่ไม่สมเหตุสมผล หรือรูปแบบข้อมูลที่ไม่สอดคล้องกัน ซึ่งอาจส่งผลต่อคุณภาพของผลการวิเคราะห์

สำหรับโครงงานนี้มีการตรวจสอบและจัดการข้อมูลซ้ำ (Duplicate Records) ข้อมูลสูญหาย (Missing Values) รูปแบบข้อมูลประเภท Category ที่ไม่สอดคล้องกัน ค่าผิดปกติ และการแปลงข้อมูลวันที่ให้อยู่ในรูปแบบที่เหมาะสม นอกจากนี้ยังมีการแยกรายการคืนสินค้าออกจากรายการซื้อก่อนนำข้อมูลไปวิเคราะห์พฤติกรรมการซื้อ

ในส่วนของการสร้างแบบจำลอง มีการสร้างตัวแปรเพิ่มเติมจากข้อมูลเดิม (Feature Engineering) เช่น RFM และตัวแปรพฤติกรรมการซื้อในช่วงเวลาต่าง ๆ รวมถึงการใช้ Log Transformation และ Standardization เพื่อเตรียมข้อมูลให้เหมาะสมกับอัลกอริทึมที่นำมาใช้

2.6 กระบวนการ CRISP-DM

CRISP-DM (Cross-Industry Standard Process for Data Mining) เป็นกระบวนการมาตรฐานที่ใช้เป็นแนวทางในการดำเนินโครงการด้านการวิเคราะห์ข้อมูล โดยช่วยให้การดำเนินงานมีขั้นตอนที่ชัดเจนตั้งแต่การกำหนดปัญหาจนถึงการนำผลลัพธ์ไปใช้งาน โครงงานนี้ประยุกต์ใช้ CRISP-DM เป็นกรอบในการดำเนินงาน โดยประกอบด้วย 6 ขั้นตอน ได้แก่

1. Business Understanding ทำความเข้าใจปัญหาและกำหนดคำถามทางธุรกิจที่ต้องการตอบ
2. Data Understanding ศึกษาโครงสร้าง ลักษณะ และคุณภาพของข้อมูลที่มีอยู่
3. Data Preparation ทำความสะอาด แปลง และเตรียมข้อมูลให้เหมาะสมสำหรับการวิเคราะห์
4. Modeling เลือกเทคนิคและสร้างแบบจำลองที่เหมาะสมกับแต่ละปัญหา
5. Evaluation ประเมินประสิทธิภาพของแบบจำลองและพิจารณาว่าสามารถตอบโจทย์ทางธุรกิจได้หรือไม่
6. Deployment นำผลการวิเคราะห์หรือแบบจำลองไปประยุกต์ใช้เพื่อสนับสนุนการตัดสินใจทางธุรกิจ

การใช้ CRISP-DM ช่วยเชื่อมโยงกระบวนการวิเคราะห์ข้อมูลกับวัตถุประสงค์ทางธุรกิจ โดยผลลัพธ์ที่ได้จากแต่ละแบบจำลองไม่ได้พิจารณาเฉพาะประสิทธิภาพทางเทคนิค แต่ยังพิจารณาถึงความสามารถในการนำไปใช้เพื่อสนับสนุนกลยุทธ์ทางธุรกิจด้วย

2.7 เครื่องมือและเทคโนโลยีที่ใช้

โครงงานนี้ใช้ Google Colab เป็นสภาพแวดล้อมหลักในการพัฒนาและประมวลผลข้อมูล โดยใช้ภาษา Python สำหรับการจัดการข้อมูล การวิเคราะห์ และการสร้างแบบจำลอง

ไลบรารีหลักที่ใช้ประกอบด้วย Pandas และ NumPy สำหรับจัดการและประมวลผลข้อมูล, MLxtend สำหรับสร้าง Frequent Itemsets และ Association Rules ด้วย Apriori และ FP-Growth, Scikit-learn สำหรับ Standardization, K-Means Clustering, Logistic Regression และการประเมินประสิทธิภาพของแบบจำลอง และ Matplotlib สำหรับสร้างกราฟและแสดงผลการวิเคราะห์

เครื่องมือดังกล่าวถูกเลือกใช้ให้เหมาะสมกับกระบวนการวิเคราะห์ทั้งสามส่วนของโครงงาน ตั้งแต่การเตรียมข้อมูล การสร้างแบบจำลอง ไปจนถึงการประเมินและนำเสนอผลลัพธ์

บทที่ 3

ขั้นตอนการดำเนินงาน

โครงงานนี้ดำเนินการตามกระบวนการ CRISP-DM เพื่อให้การวิเคราะห์ข้อมูลเป็นไปอย่างเป็นระบบ ตั้งแต่การทำความเข้าใจปัญหาทางธุรกิจ การสำรวจและเตรียมข้อมูล การสร้างแบบจำลอง การประเมินผล และการนำผลลัพธ์ไปประยุกต์ใช้ โดยกระบวนการดำเนินงานประกอบด้วย 6 ขั้นตอน ได้แก่ Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation และ Deployment

3.1 ภาพรวมกระบวนการทำงาน

กระบวนการดำเนินงานเริ่มจากการกำหนดปัญหาและคำถามทางธุรกิจ จากนั้นศึกษาชุดข้อมูลและตรวจสอบคุณภาพของข้อมูล ก่อนทำความสะอาดและแปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการวิเคราะห์ หลังจากนั้นจึงสร้างแบบจำลองสำหรับปัญหาทางธุรกิจทั้ง 3 ด้าน ประเมินผล และนำผลลัพธ์ที่ได้ไปกำหนดแนวทางในการประยุกต์ใช้เชิงธุรกิจ



รูปที่ 3.1 กระบวนการดำเนินงานตาม CRISP-DM

3.2 Business Understanding

ขั้นตอน Business Understanding เป็นการกำหนดปัญหาและเป้าหมายของการวิเคราะห์ให้สอดคล้องกับความต้องการทางธุรกิจ โดยโครงงานนี้มุ่งเน้นการนำข้อมูลลูกค้าและธุรกรรมมาใช้สนับสนุนกลยุทธ์ด้านการเพิ่มยอดขายและการรักษาฐานลูกค้า

3.2.1 ปัญหาทางธุรกิจ

โครงงานกำหนดปัญหาทางธุรกิจออกเป็น 3 ด้าน ได้แก่ การเพิ่มจำนวนสินค้าและมูลค่าการซื้อต่อธุรกรรม การทำความเข้าใจความแตกต่างของลูกค้าแต่ละกลุ่ม และการระบุลูกค้าที่มีแนวโน้มจะหยุดซื้อสินค้า เพื่อให้ธุรกิจสามารถนำข้อมูลไปใช้ประกอบการวางแผนกลยุทธ์ได้อย่างเหมาะสม

3.2.2 คำถามทางธุรกิจ

กำหนดคำถามทางธุรกิจสำหรับการวิเคราะห์ ดังนี้

1. Increase Basket Size: สินค้าใดมักถูกซื้อร่วมกัน และคู่หรือกลุ่มสินค้าใดเหมาะสำหรับนำมาจัดโปรโมชันร่วมกันเพื่อเพิ่ม Basket Size
2. Customer Segmentation: พฤติกรรมการซื้อสามารถแบ่งลูกค้าออกเป็นกี่กลุ่ม และลูกค้าแต่ละกลุ่มมีลักษณะเด่นแตกต่างกันอย่างไร
3. Customer Retention: ลูกค้ารายใดมีแนวโน้มจะหยุดซื้อ และพฤติกรรมใดเป็นสัญญาณเตือนที่สัมพันธ์กับการ Churn

3.2.3 เป้าหมายของการวิเคราะห์

การวิเคราะห์มีเป้าหมายเพื่อค้นหาความสัมพันธ์ของสินค้าที่สามารถนำไปใช้กับ Cross-selling และ Bundle Promotion แบ่งกลุ่มลูกค้าตามพฤติกรรมเพื่อสนับสนุนการทำ Targeted Marketing และสร้างแบบจำลองสำหรับระบุลูกค้าที่มีความเสี่ยง Churn เพื่อสนับสนุนการดำเนินมาตรการรักษาลูกค้าล่วงหน้า

3.2.4 เกณฑ์ความสำเร็จของโครงงาน

เกณฑ์ความสำเร็จพิจารณาจากความสามารถในการตอบคำถามทางธุรกิจทั้ง 3 ด้าน โดย Association Rules พิจารณาจาก Support, Confidence และ Lift การแบ่งกลุ่มลูกค้าพิจารณาจาก Elbow Method, Silhouette Score และความสามารถในการตีความกลุ่ม และ Customer Retention พิจารณาจาก Precision, Recall, F1-Score, ROC-AUC และ PR-AUC โดยให้ความสำคัญกับ Recall เพื่อให้สามารถตรวจพบลูกค้าที่มีความเสี่ยง Churn ได้มากขึ้น

3.3 Data Understanding

ชุดข้อมูลที่ใช้ในโครงงานประกอบด้วยข้อมูลหลักจำนวน 6 ตาราง ได้แก่ Customers, Products, Transactions, Transaction Items, Support Tickets และ Churn Labels ซึ่งสามารถเชื่อมโยงกันผ่าน Customer ID, Transaction ID และ Product ID ตามวัตถุประสงค์ของการวิเคราะห์แต่ละส่วน

3.3.1 รายละเอียดชุดข้อมูล

ตารางที่ 3.1 สรุปชุดข้อมูลที่ใช้ในโครงงาน

ชุดข้อมูล	จำนวนแถว (Rows)	จำนวนคอลัมน์ (Columns)	รายละเอียด
Customers	3,015	11	ข้อมูลพื้นฐานและคุณลักษณะของลูกค้า
Products	89	4	ข้อมูลรายละเอียดสินค้า
Transactions	66,999	12	ข้อมูลธุรกรรมการซื้อและการคืนสินค้า
Transaction Items	375,088	7	รายละเอียดสินค้าในแต่ละธุรกรรม
Support Tickets	1,636	7	ข้อมูลการติดต่อและการให้บริการลูกค้า
Churn Labels	3,000	8	ข้อมูลสถานะการหยุดซื้อของลูกค้า

จากตารางที่ 3.1 ชุดข้อมูลแต่ละส่วนมีหน้าที่แตกต่างกัน โดยข้อมูล Customers ใช้สำหรับระบุคุณลักษณะของลูกค้า ข้อมูล Transactions และ Transaction Items ใช้สำหรับศึกษาพฤติกรรมการซื้อ ข้อมูล Products ใช้สำหรับระบุรายละเอียดของสินค้า ข้อมูล Support Tickets ใช้ประกอบการวิเคราะห์ด้านการรับบริการของลูกค้า และข้อมูล Churn Labels ใช้สำหรับกำหนดสถานะของลูกค้าในการวิเคราะห์ Customer Retention

3.3.2 การสำรวจและตรวจสอบคุณภาพข้อมูล

จากการสำรวจข้อมูลเบื้องต้นพบประเด็นด้านคุณภาพข้อมูลหลายประการ ได้แก่ Duplicate Records ใน Customers และ Transactions, Missing Values ในตัวแปรบางส่วนของ Customers, รูปแบบ Gender ที่ไม่สอดคล้องกัน ค่า Age ที่ไม่สมเหตุสมผล และ Quantity Outliers

นอกจากนี้ยังพบรายการคืนสินค้า ซึ่งมีจำนวนและมูลค่าติดลบ จึงจำเป็นต้องแยกออกจาก Purchase Transactions ก่อนนำไปวิเคราะห์ รวมถึงมีการตรวจสอบตัวแปรวันที่และความเสี่ยงต่อ Data Leakage จากข้อมูล Churn Labels ก่อนเข้าสู่ขั้นตอนการเตรียมข้อมูล

3.4 Data Preparation

ขั้นตอน Data Preparation เป็นการปรับปรุงข้อมูลให้อยู่ในรูปแบบที่เหมาะสมกับการวิเคราะห์แต่ละประเภท โดยดำเนินการทั้งการทำความสะอาดข้อมูล การแปลงข้อมูล และการสร้างตัวแปรเพิ่มเติม

3.4.1 การทำความสะอาดข้อมูล

ดำเนินการลบข้อมูลซ้ำโดยพิจารณาจาก Primary Key ของแต่ละตาราง ปรับรูปแบบข้อมูล Gender ให้เป็นมาตรฐาน และจัดการค่า Age ที่ไม่สมเหตุสมผลโดยกำหนดให้เป็น Missing Value ก่อนแทนค่าด้วยค่ามัธยฐาน ส่วน Missing Values ใน Region และ Income Bracket กำหนดเป็น Unknown

ตัวแปรวันที่ เช่น signup_date, reference_date, first_purchase_date, last_purchase_date และ ticket_date ถูกแปลงให้อยู่ในรูปแบบ Datetime เพื่อรองรับการวิเคราะห์ตามช่วงเวลา

3.4.2 การเตรียมข้อมูลสำหรับ Basket Analysis

สำหรับ Market Basket Analysis เลือกเฉพาะ Purchase Transactions และรายการสินค้าที่มี Quantity มากกว่า 0 จากนั้นเชื่อมข้อมูล Transaction Items กับ Products และจัดข้อมูลให้อยู่ในรูปแบบรายการสินค้าในแต่ละ Basket ก่อนทำ Transaction Encoding เพื่อใช้กับ Apriori และ FP-Growth

3.4.3 การเตรียมข้อมูลสำหรับ Customer Segmentation

เลือกเฉพาะ Purchase Transactions และสร้างตัวแปร RFM ประกอบด้วย Recency, Frequency และ Monetary สำหรับลูกค้าแต่ละราย จากนั้นตรวจสอบการกระจายของข้อมูล และใช้ Log Transformation ร่วมกับ Standardization ก่อนนำข้อมูลเข้าสู่ K-Means Clustering

3.4.4 การเตรียมข้อมูลสำหรับ Customer Retention

การวิเคราะห์ Customer Retention กำหนด Feature Window ระหว่างวันที่ 1 กันยายน 2024 ถึง 1 มิถุนายน 2026 และ Outcome Window ระหว่างวันที่ 2 มิถุนายน ถึง 31 สิงหาคม 2026 เพื่อป้องกัน Data Leakage

สร้าง Features จากพฤติกรรมของลูกค้า เช่น Recency จำนวน Transaction ในช่วง 30, 90, 180 และ 365 วัน ยอดใช้จ่าย มูลค่าต่อ Basket การใช้ส่วนลด ความหลากหลายของสินค้าและช่องทาง และข้อมูล Support Tickets

จากลูกค้าทั้งหมด 3,000 คน พบว่ามีลูกค้า 2,876 คน ที่มีประวัติการซื้อภายใน Feature Window และสามารถนำมาใช้สร้าง Behavioral Features ได้ จึงกำหนดลูกค้ากลุ่มดังกล่าวเป็น Modeling Population โดยประกอบด้วย Non-Churn 2,133 คน และ Churn 743 คน

3.5 Modeling

หลังจากเตรียมข้อมูลแล้ว จึงดำเนินการสร้างแบบจำลองแยกตามปัญหาทางธุรกิจทั้ง 3 ด้าน

3.5.1 การวิเคราะห์ Increase Basket Size

ใช้ Association Rule Mining โดยเปรียบเทียบ Apriori และ FP-Growth ภายใต้เกณฑ์เดียวกัน ทั้งสองวิธีใช้สำหรับสร้าง Frequent Itemsets ก่อนนำมาสร้าง Association Rules และคัดเลือกความสัมพันธ์ของสินค้าที่มีความเหมาะสมสำหรับการนำไปใช้เชิงธุรกิจ

3.5.2 การแบ่งกลุ่มลูกค้า

ใช้ RFM เป็น Features สำหรับแบ่งกลุ่มลูกค้าด้วย K-Means Clustering โดยทดลองจำนวน Cluster หลายค่าและพิจารณาจำนวนกลุ่มที่เหมาะสมด้วย Elbow Method และ Silhouette Score ร่วมกับความสามารถในการตีความลักษณะของลูกค้าแต่ละกลุ่ม

หลังจากเลือกจำนวน Cluster แล้วจึงสร้าง Final K-Means Model และวิเคราะห์ Cluster Profile เพื่อกำหนดลักษณะของลูกค้าในแต่ละกลุ่ม

3.5.3 การวิเคราะห์ Customer Retention

กำหนดปัญหาเป็น Binary Classification โดย 1 แทนลูกค้า Churn และ 0 แทนลูกค้า Active จากนั้นแบ่งข้อมูลสำหรับ Training และ Testing และปรับ Scale ของ Features ก่อนสร้างแบบจำลอง Logistic Regression

มีการทดลอง Logistic Regression หลายรูปแบบ ได้แก่ Baseline Logistic Regression, Balanced Logistic Regression และ Balanced Logistic Regression ที่เพิ่ม Purchase Trend Feature เพื่อเปรียบเทียบและเลือกโมเดลที่เหมาะสมกับวัตถุประสงค์ด้าน Customer Retention

3.6 Evaluation

การประเมินผลดำเนินการแตกต่างกันตามลักษณะของแต่ละปัญหา โดย Association Rules ประเมินด้วย Support, Confidence, Lift จำนวน Frequent Itemsets และ Execution Time

Customer Segmentation ประเมินด้วย Elbow Method และ Silhouette Score ร่วมกับการวิเคราะห์ Cluster Profile และความสามารถในการตีความกลุ่มในเชิงธุรกิจ

ส่วน Customer Retention ประเมินด้วย Accuracy, Precision, Recall, F1-Score, ROC-AUC และ PR-AUC โดยให้ความสำคัญกับ Recall เนื่องจากต้องการลดจำนวนลูกค้าที่มีความเสี่ยง Churn แต่โมเดลไม่สามารถตรวจพบได้

3.7 Deployment

ผลการวิเคราะห์ถูกออกแบบให้อยู่ในรูปแบบที่สามารถนำไปประยุกต์ใช้ในการตัดสินใจทางธุรกิจได้ โดยผล Association Rules สามารถนำไปสร้างคำแนะนำ Product ⟶ Recommended Product สำหรับ Cross-selling และ Bundle Promotion

ผล Customer Segmentation สามารถนำไปสร้าง Customer ⟶ Segment ⟶ Recommended Action เพื่อกำหนดแนวทางการตลาดให้เหมาะสมกับลูกค้าแต่ละกลุ่ม ส่วน Customer Retention สามารถนำ Churn Probability มาจัดระดับความเสี่ยงและกำหนด Recommended Action สำหรับลูกค้าแต่ละราย

แนวทางการนำไปใช้งานสามารถสรุปเป็นกระบวนการ New Data ⟶ Data Preparation ⟶ Models ⟶ Business Actions ⟶ Monitoring เพื่อให้สามารถปรับปรุงผลการวิเคราะห์เมื่อมีข้อมูลใหม่ในอนาคต

บทที่ 4

ผลการดำเนินงาน

บทนี้นำเสนอผลลัพธ์จากการวิเคราะห์ข้อมูลตามปัญหาทางธุรกิจทั้ง 3 ด้าน ได้แก่ Increase Basket Size, Customer Segmentation และ Customer Retention รวมถึงการประเมินประสิทธิภาพและการตีความผลลัพธ์ในเชิงธุรกิจ

4.1 ผลการเตรียมและสำรวจข้อมูล

หลังจากดำเนินการตรวจสอบและทำความสะอาดข้อมูล ข้อมูลที่ไม่เหมาะสม เช่น Duplicate Records รูปแบบข้อมูลที่ไม่สอดคล้องกัน Missing Values และค่าที่ไม่สมเหตุสมผลได้รับการจัดการก่อนนำไปวิเคราะห์

สำหรับ Customer Retention หลังจากกำหนด Feature Window พบว่ามีลูกค้า 2,876 คนที่สามารถนำมาใช้สร้าง Features ได้ จากลูกค้าทั้งหมด 3,000 คน โดยแบ่งเป็น Non-Churn จำนวน 2,133 คน หรือ 74.17% และ Churn จำนวน 743 คน หรือ 25.83% แสดงให้เห็นว่าข้อมูลมี Class Imbalance ในระดับหนึ่ง

4.2 ผลการวิเคราะห์ Increase Basket Size

ตารางที่ 4.1 ผลการเปรียบเทียบ Apriori และ FP-Growth

Algorithm	Runtime (seconds)	Frequent Itemsets	Association Rules
Apriori	14.7761	410	96
FP-Growth	110.4343	410	96

จากตารางที่ 4.1 พบว่า Apriori และ FP-Growth สามารถค้นหา Frequent Itemsets ได้จำนวน 410 ชุด และ Association Rules จำนวน 96 กฎเท่ากัน อย่างไรก็ตาม Apriori ใช้เวลาในการประมวลผล 14.7761 วินาที ขณะที่ FP-Growth ใช้เวลา 110.4343 วินาที แสดงให้เห็นว่า Apriori มีระยะเวลาในการประมวลผลน้อยกว่าสำหรับชุดข้อมูลที่ใช้ในโครงงานนี้

ตารางที่ 4.2 กฎความสัมพันธ์ของสินค้าที่มีค่า Lift สูงสุด 10 อันดับ

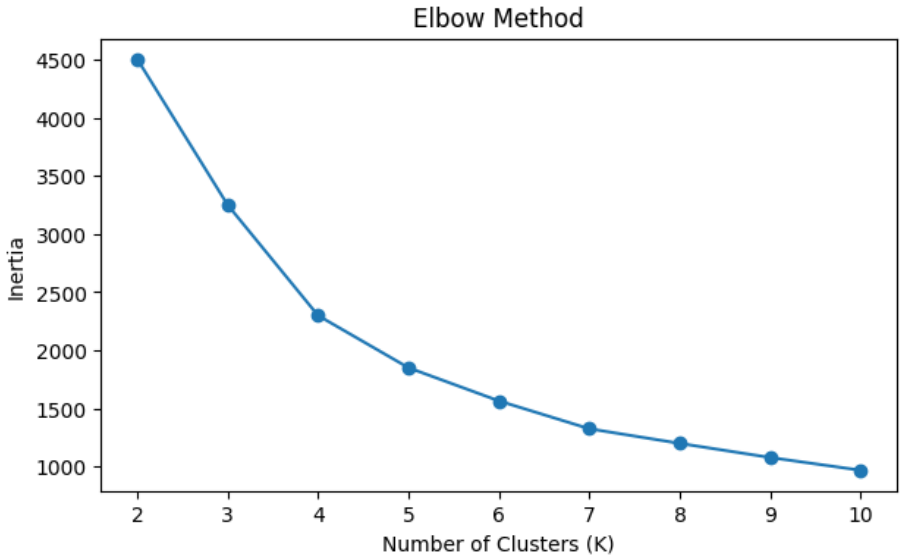
antecedents	consequents	support	confidence	lift
Coffee Creamer	Coffee Filter Paper	0.030129	0.652117	11.689890
Coffee Filter Paper	Coffee Creamer	0.030129	0.540092	11.689890
Pet Shampoo	Dog Treats	0.012540	0.497294	11.646499
Baby Lotion	Baby Wipes	0.021425	0.660280	10.897270
Baby Wipes	Baby Lotion	0.021425	0.353604	10.897270
Baby Lotion	Diapers Pack	0.021804	0.671963	10.097046
Diapers Pack	Baby Lotion	0.021804	0.327637	10.097046
Dog Treats	Dog Food 3kg	0.023366	0.547230	9.698959
Dog Food 3kg	Dog Treats	0.023366	0.414136	9.698959
Coffee Filter Paper	Coffee Beans 250g	0.040136	0.719489	9.412874

จากตารางที่ 4.2 พบว่ากฎความสัมพันธ์ที่มีค่า Lift สูงที่สุดคือ Coffee Creamer ⟶ Coffee Filter Paper และ Coffee Filter Paper ⟶ Coffee Creamer โดยมีค่า Lift เท่ากับ 11.689890 แสดงว่าสินค้าทั้งสองมีแนวโน้มถูกซื้อร่วมกันสูงเมื่อเทียบกับการเกิดขึ้นอย่างเป็นอิสระ นอกจากนี้ยังพบความสัมพันธ์ที่เด่นชัดในกลุ่มสินค้าอื่น เช่น Pet Shampoo ⟶ Dog Treats, Baby Lotion ⟶ Baby Wipes และ Baby Lotion ⟶ Diapers Pack ซึ่งมีค่า Lift มากกว่า 10 เช่นเดียวกัน

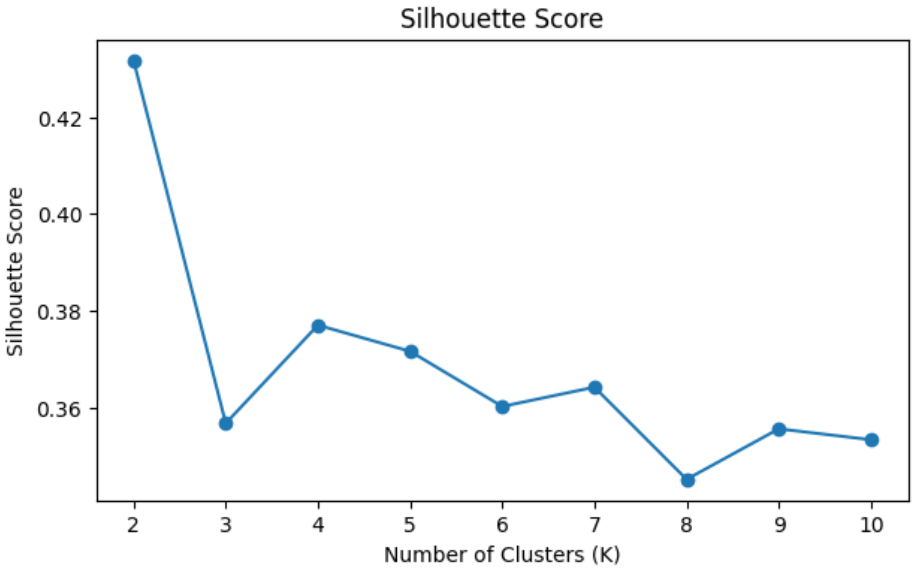
เมื่อพิจารณาร่วมกับค่า Support และ Confidence พบว่ากฎแต่ละรายการมีระดับความถี่และความน่าเชื่อถือแตกต่างกัน ตัวอย่างเช่น Coffee Filter Paper ⟶ Coffee Beans 250g มีค่า Confidence เท่ากับ 0.719489 ซึ่งหมายความว่า ในธุรกรรมที่มี Coffee Filter Paper มีประมาณร้อยละ 71.95 ที่พบ Coffee Beans 250g ร่วมด้วย ผลการวิเคราะห์ดังกล่าวสามารถนำไปใช้เป็นแนวทางในการเลือกคู่สินค้าสำหรับ Cross-selling, Bundle Promotion และ Product Recommendation เพื่อสนับสนุนการเพิ่มมูลค่าการซื้อต่อธุรกรรม

4.3 ผลการแบ่งกลุ่มลูกค้า

4.3.1 ผลการเลือกจำนวน Cluster



รูปที่ 4.1 ผลการเลือกจำนวนกลุ่มด้วย Elbow Method



รูปที่ 4.2 ผลการประเมินจำนวนกลุ่มด้วย Silhouette Score

จากการทดลองจำนวน Cluster ด้วย Elbow Method และ Silhouette Score พบว่า Silhouette Score มีค่าสูงสุดที่ K = 2 อย่างไรก็ตาม เมื่อพิจารณาร่วมกับ Elbow Method และความสามารถในการตีความ

กลุ่มในเชิงธุรกิจ พบว่า K = 4 สามารถแบ่งลูกค้าออกเป็นกลุ่มที่มีลักษณะพฤติกรรมแตกต่างกันและสามารถนำไปกำหนดกลยุทธ์ได้อย่างเหมาะสม จึงเลือกใช้ K = 4 สำหรับ Final K-Means Model

4.3.2 ลักษณะของลูกค้าแต่ละกลุ่ม

ตารางที่ 4.3 ผลการแบ่งกลุ่มด้วย RFM และ K-Means

กลุ่ม	จำนวน	ลักษณะสำคัญ
At-Risk Valuable Customers	887	เคยซื้อบ่อยและมียอดใช้จ่ายค่อนข้างสูง แต่เริ่มห่างจากการซื้อ
Recent / Developing Customers	587	เพิ่งมีการซื้อไม่นาน แต่ Frequency และ Monetary ยังไม่สูง
Inactive / Low-Value Customers	863	ซื้อไม่บ่อย มูลค่าต่ำ และไม่ได้กลับมาซื้อเป็นเวลานาน
High-Value / Loyal Customers	663	มีพฤติกรรมการซื้อและมูลค่าที่สะท้อนถึงกลุ่มลูกค้าคุณค่าสูง

4.4 ผลการวิเคราะห์ Customer Retention

4.4.1 ผลการเปรียบเทียบแบบจำลอง

ตารางที่ 4.4 ผลการเปรียบเทียบประสิทธิภาพของแบบจำลอง Customer Retention

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Baseline Logistic Regression	0.8090	0.7294	0.4161	0.5299	0.8369	0.6753
Balanced Logistic Regression	0.7552	0.5192	0.7248	0.6050	0.8375	0.6676
Balanced Logistic +	0.7569	0.5217	0.7248	0.6067	0.8377	0.6675

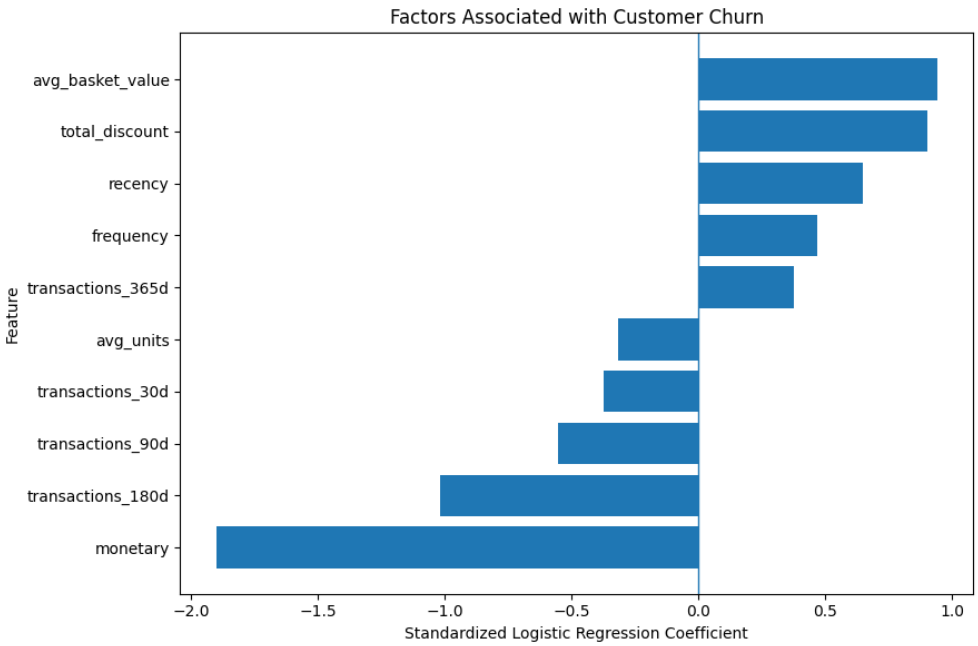
Purchase Trend						

จากตารางที่ 4.4 มีการเปรียบเทียบ Logistic Regression จำนวน 3 รูปแบบ ได้แก่ Baseline Logistic Regression, Balanced Logistic Regression และ Balanced Logistic Regression ที่เพิ่ม Purchase Trend Feature โดย Baseline Logistic Regression มีค่า Accuracy สูงที่สุดที่ 80.90% แต่มีค่า Recall สำหรับกลุ่ม Churn เพียง 41.61%

เมื่อปรับน้ำหนักของแต่ละคลาสด้วย class_weight = "balanced" พบว่า Recall เพิ่มขึ้นเป็น 72.48% และจำนวน False Negative ลดลงจาก 87 คนเหลือ 41 คน ขณะที่การเพิ่ม Purchase Trend Feature ยังคงให้ Recall เท่ากันที่ 72.48% และทำให้ F1-Score และ ROC-AUC เพิ่มขึ้นเพียงเล็กน้อย

ดังนั้น จึงเลือก Balanced Logistic Regression เป็น Final Model เนื่องจากมีโครงสร้างไม่ซับซ้อน สามารถตีความได้ และสามารถตรวจพบลูกค้าที่ Churn ได้มากกว่า Baseline Model ซึ่งสอดคล้องกับวัตถุประสงค์ด้าน Customer Retention

4.4.2 พฤติกรรมที่สัมพันธ์กับ Customer Churn



รูปที่ 4.3 ปัจจัยที่สัมพันธ์กับการหยุดซื้อของลูกค้า

จากค่า Coefficient ของ Final Model พบว่าปัจจัยสำคัญที่สัมพันธ์กับการ Churn ของลูกค้า ได้แก่ ค่า Recency ที่สูงขึ้น กิจกรรมการซื้อในช่วง 30–180 วันที่ลดลง มูลค่าการซื้อสะสมที่ต่ำ และจำนวนสินค้าต่อธุรกรรมที่ต่ำ ซึ่งสามารถใช้เป็นสัญญาณประกอบการระบุลูกค้าที่มีแนวโน้มจะหยุดซื้อได้

อย่างไรก็ตาม ตัวแปรที่เกี่ยวข้องกับ Frequency และจำนวนธุรกรรมในแต่ละช่วงเวลามีความสัมพันธ์กันค่อนข้างสูง จึงควรตีความค่า Coefficient ในบริบทของความสัมพันธ์เชิงการทำนาย และไม่ควรนำไปสรุปว่าเป็นความสัมพันธ์เชิงเหตุและผลโดยตรง

4.4.3 การตีความเชิงธุรกิจ

Final Model สามารถนำไปคำนวณ Churn Probability และจัดระดับความเสี่ยงของลูกค้า เพื่อช่วยให้ธุรกิจเลือกกลุ่มเป้าหมายสำหรับ Retention Campaign ได้

ตารางที่ 4.5 ตัวอย่างลูกค้าที่มีความเสี่ยงต่อการ Churn สูง

customer_id	Recency	Frequency	Monetary	Segment	Recommended_Action
C10001	180	7	7401.33	Inactive / Low-Value	Low-cost Re-engagement Campaign
C10002	4	8	3282.67	Recent / Developing	Second-purchase Promotion / Cross-selling
C10003	154	4	3110.29	Inactive / Low-Value	Low-cost Re-engagement Campaign
C10004	10	6	2507.13	Recent / Developing	Second-purchase Promotion / Cross-selling
C10005	4	12	6843.47	Recent / Developing	Second-purchase Promotion / Cross-selling

C10006	81	12	7232.42	Inactive / Low-Value	Low-cost Re-engagement Campaign
C10007	1	5	9399.24	Recent / Developing	Second-purchase Promotion / Cross-selling
C10008	58	2	3039.52	Inactive / Low-Value	Low-cost Re-engagement Campaign
C10009	34	4	1905.10	Inactive / Low-Value	Low-cost Re-engagement Campaign
C10010	119	15	11237.07	At-Risk Valuable	Win-back Campaign / Personalized Reminder

จากตารางที่ 4.5 แสดงตัวอย่างลูกค้าที่มีค่า Churn Probability สูง ซึ่งสามารถนำมาใช้จัดลำดับความสำคัญสำหรับการดำเนิน Retention Campaign และกำหนดแนวทางในการดูแลลูกค้าแต่ละรายได้

ลูกค้าที่มี Recency สูง มีกิจกรรมการซื้อช่วงล่าสุดต่ำ และมีมูลค่าการซื้อสะสมต่ำควรได้รับการติดตาม โดยอาจใช้ Personalized Reminder, Product Recommendation, Win-back Campaign หรือ Promotion เพื่อกระตุ้นการกลับมาซื้อสินค้า

สำหรับลูกค้าที่มีความเสี่ยงสูงและเคยสร้างมูลค่าให้กับธุรกิจสูง ควรได้รับความสำคัญเป็นพิเศษ เพื่อให้ทรัพยากรสำหรับ Retention Campaign ถูกใช้กับลูกค้าที่มีมูลค่าทางธุรกิจสูงก่อน

บทที่ 5

สรุปผลการดำเนินงาน

5.1 สรุปผลการดำเนินโครงงาน

โครงงานนี้นำแนวทาง Customer Analytics มาใช้เพื่อสนับสนุนการพัฒนากลยุทธ์ในการเพิ่มยอดขายและรักษาฐานลูกค้า โดยดำเนินงานตามกระบวนการ CRISP-DM และแบ่งการวิเคราะห์ออกเป็น 3 ด้าน ได้แก่ Increase Basket Size, Customer Segmentation และ Customer Retention

ผลการดำเนินงานแสดงให้เห็นว่า ข้อมูลลูกค้าและข้อมูลธุรกรรมสามารถนำมาใช้ในการค้นหาความสัมพันธ์ระหว่างสินค้า การแบ่งกลุ่มลูกค้าตามพฤติกรรมการซื้อ และการสร้างแบบจำลองเพื่อระบุลูกค้าที่มีแนวโน้มจะหยุดซื้อ ซึ่งผลการวิเคราะห์ที่ได้สามารถนำไปใช้เป็นข้อมูลประกอบการวางแผนกลยุทธ์และสนับสนุนการตัดสินใจทางธุรกิจได้

5.2 สรุปผลตามคำถามทางธุรกิจ

5.2.1 Increase Basket Size

การวิเคราะห์ด้วย Association Rule Mining สามารถค้นหาสินค้าที่มีแนวโน้มถูกซื้อร่วมกันได้ โดย Apriori และ FP-Growth ให้จำนวน Frequent Itemsets และ Association Rules เท่ากันภายใต้เงื่อนไขเดียวกัน ทั้งนี้ กฎความสัมพันธ์ที่ได้สามารถนำไปใช้เป็นแนวทางในการทำ Cross-selling, Bundle Promotion และ Product Recommendation เพื่อสนับสนุนการเพิ่มมูลค่าการซื้อต่อธุรกรรม

5.2.2 Customer Segmentation

การวิเคราะห์ด้วย RFM ร่วมกับ K-Means สามารถแบ่งลูกค้าออกเป็น 4 กลุ่ม ได้แก่ High-Value / Loyal, Recent / Developing, At-Risk Valuable และ Inactive / Low-Value โดยแต่ละกลุ่มมีลักษณะและพฤติกรรมการซื้อที่แตกต่างกัน ซึ่งสามารถนำไปใช้เป็นแนวทางในการกำหนดกลยุทธ์ทางการตลาดและการดูแลลูกค้าให้เหมาะสมกับแต่ละกลุ่ม

5.2.3 Customer Retention

ผลการเปรียบเทียบแบบจำลองพบว่า Balanced Logistic Regression มีความเหมาะสมกับวัตถุประสงค์ของโครงงานมากกว่า Baseline Model เนื่องจากสามารถเพิ่มค่า Recall สำหรับกลุ่ม Churn จาก 41.61% เป็น 72.48% และลดจำนวน False Negative จาก 87 คนเหลือ 41 คน ส่งผลให้สามารถตรวจพบลูกค้าที่มีแนวโน้มจะหยุดซื้อได้มากขึ้น และสามารถนำผลที่ได้ไปใช้ประกอบการวางแผนมาตรการรักษาลูกค้าได้อย่างเหมาะสม

5.3 ข้อเสนอแนะเชิงธุรกิจ

จากผลการวิเคราะห์ สามารถนำ Association Rules ไปใช้เป็นแนวทางในการจัด Bundle Promotion และการทำ Cross-selling เพื่อสนับสนุนการเพิ่ม Basket Size ขณะที่ผลจาก Customer Segmentation สามารถนำไปใช้กำหนดกลยุทธ์ให้เหมาะสมกับลูกค้าแต่ละกลุ่ม เช่น การมอบสิทธิประโยชน์เพื่อรักษากลุ่ม High-Value / Loyal Customers การกระตุ้นให้เกิดการซื้อซ้ำในกลุ่ม Recent / Developing Customers และการจัด Win-back Campaign เพื่อดึงดูดกลุ่ม At-Risk Valuable Customers ให้กลับมาซื้อสินค้า

สำหรับ Customer Retention ธุรกิจสามารถนำ Churn Probability มาใช้จัดระดับความเสี่ยงและจัดลำดับความสำคัญของลูกค้า โดยให้ความสำคัญกับลูกค้าที่มีความเสี่ยงสูงและเคยสร้างมูลค่าให้กับธุรกิจ เพื่อช่วยให้การวางแผน Promotion และ Retention Campaign สามารถกำหนดกลุ่มเป้าหมายได้อย่างเหมาะสมและใช้ทรัพยากรได้อย่างมีประสิทธิภาพมากขึ้น

5.4 ข้อจำกัดของโครงงาน

Association Rules แสดงถึงความสัมพันธ์ของสินค้าที่มีแนวโน้มถูกซื้อร่วมกัน แต่ไม่สามารถใช้สรุปความสัมพันธ์เชิงเหตุและผลได้ นอกจากนี้ รูปแบบการซื้อของลูกค้าอาจเปลี่ยนแปลงตามช่วงเวลา ฤดูกาล และ Promotion จึงควรมีการปรับปรุงกฎความสัมพันธ์ให้สอดคล้องกับข้อมูลใหม่อยู่เสมอ

สำหรับ Customer Segmentation เนื่องจาก K-Means เป็นวิธีการเรียนรู้แบบ Unsupervised Learning จึงไม่มี Ground Truth สำหรับใช้ยืนยันความถูกต้องของการแบ่งกลุ่มโดยตรง อีกทั้งพฤติกรรมของลูกค้าสามารถเปลี่ยนแปลงได้ตามเวลา ซึ่งอาจส่งผลให้ลูกค้าเปลี่ยนจาก Segment หนึ่งไปยังอีก Segment หนึ่ง

ส่วน Customer Retention แม้ Final Model จะมีค่า Recall เท่ากับ 72.48% แต่มีค่า Precision เท่ากับ 51.92% จึงยังมีกรณีที่โมเดลคาดการณ์ว่าลูกค้ามีแนวโน้ม Churn แต่ลูกค้าไม่ได้ Churn จริง หรือ False Positive อยู่ นอกจากนี้ Features บางส่วนมี Correlation กันค่อนข้างสูง ดังนั้นค่า Coefficient ของ Logistic Regression จึงควรใช้เพื่ออธิบายความสัมพันธ์เชิงการทำนาย และไม่ควรนำไปตีความเป็นความสัมพันธ์เชิงเหตุและผลโดยตรง

5.5 แนวทางการพัฒนาในอนาคต

ในอนาคตสามารถทดลองใช้ Classification Algorithms อื่น ๆ และพัฒนา Behavioral Features เพิ่มเติม เพื่อเพิ่มประสิทธิภาพในการตรวจจับลูกค้าที่มีแนวโน้ม Churn รวมถึงปรับ Churn Probability Threshold ให้เหมาะสมกับต้นทุนของ Retention Campaign และมูลค่าของลูกค้าแต่ละราย เพื่อให้การระบุกลุ่มลูกค้าที่มีความเสี่ยงมีความเหมาะสมกับการนำไปใช้งานจริงมากยิ่งขึ้น

นอกจากนี้ ควรนำแนวทางที่ได้จากการวิเคราะห์ เช่น Promotion, Product Recommendation และ Retention Campaign ไปทดลองใช้งานจริงและประเมินผล เช่น การทำ A/B Testing เพื่อศึกษาประสิทธิผลของกลยุทธ์ที่นำเสนอ รวมถึงปรับปรุง Association Rules, Customer Segments และ Churn Model เป็นระยะเมื่อมีข้อมูลธุรกรรมใหม่ เพื่อให้ผลการวิเคราะห์ยังคงสอดคล้องกับพฤติกรรมของลูกค้าที่เปลี่ยนแปลงไปตามเวลา

บรรณานุกรม

IBM. (2567). *IBM SPSS Modeler CRISP-DM Guide*. สืบค้นจาก IBM Documentation

Raschka, S. (ม.ป.ป.). *Apriori*. MLxtend Documentation. สืบค้นจาก MLxtend: Apriori

Raschka, S. (ม.ป.ป.). *FP-Growth*. MLxtend Documentation. สืบค้นจาก MLxtend: FP-Growth

Raschka, S. (ม.ป.ป.). *Association Rules*. MLxtend Documentation. สืบค้นจาก MLxtend: Association Rules

Scikit-learn Developers. (ม.ป.ป.). *KMeans*. Scikit-learn Documentation. สืบค้นจาก Scikit-learn: KMeans

Scikit-learn Developers. (ม.ป.ป.). *Selecting the number of clusters with silhouette analysis on KMeans clustering*. Scikit-learn Documentation. สืบค้นจาก Scikit-learn: Silhouette Analysis

Scikit-learn Developers. (ม.ป.ป.). *LogisticRegression*. Scikit-learn Documentation. สืบค้นจาก Scikit-learn: Logistic Regression

Scikit-learn Developers. (ม.ป.ป.). *Metrics and scoring*. Scikit-learn Documentation. สืบค้นจาก Scikit-learn: Metrics and Scoring